

# 一，项目总体理解

## 本项目需要建立一条业务问题到留存行为的分析链路

包括：数据验证，数据清洗；客户流失预测，流失原因分析，客户价值判断；干预措施决策，实验/因果论证；计算收益/ROI

## 项目目的在于回答下述问题

1. 谁可能流失？ 给每位客户一个经过校准的风险概率。
2. 为什么可能流失？ 找到整体和单个客户的主要风险因素。
3. 谁最值得优先处理？ 将流失风险与 CLV、毛利和干预成本结合。
4. 怎样证明挽留有效？ 通过 A/B 测试、uplift 或因果推断估计增量效果。

## 对于项目成功的判断依据：

1. 数据可信：数据来源、字段含义、质量问题和处理规则都有记录。
2. 模型可信：切分方式合理，无数据泄漏；同时报告 AUC、PR-AUC、F1、召回率、精确率、校准和分群表现。
3. 业务可用：风险分数能够对应客户、原因、价值、行动和负责人，而不是停留在 Notebook。
4. 效果可证：明确区分相关性、预测效果和干预的因果效果，并报告成本、不确定性和限制。

# 二，第一周任务理解

## 第一周目的：

1. 明确客户、流失、预测时间和价值的含义。
2. 确认数据来源，并系统发现质量问题。
3. 把任务、依赖、验收标准和风险写成路线图

## 第一周工作包分化：

1. 业务与客户流失研究

理解 Azure 场景中的客户旅程，先确定待验证假设，再对其逐步验证

2. 数据理解与数据合同

对 PDF 中给的数据进行理解确认，并确定数据标准

3. 数据质量评估

调用 info 函数进行基础检查，再依据数据进行多维度检查，包括完整性，唯一性，合法范围等

4. 路线图与风险登记

将 8 周计划转成自己的可执行任务，并建立风险登记表。优先记录：数据获取失败、字段不匹配、时间字段不足、模型指标不达标、算力和 Azure 费用、隐私与发布风险。

# 三，个人每周计划

暂按每周 25-30 小时规划：学习与查资料约 20%，编码与实验约 45%，分析与文档约 25%，复盘与项目管理约 10%。如果某周时间减少，优先保证可复现的主流程和真实记录，删减高级加分项，不牺牲数据质量和独立测试。

为了防止只写代码、不形成成果，我每周采用相同节奏：

- 1. 周初定义：写清本周问题、输入、输出和不做什么。
- 2. 周中实现：先完成最小可运行版本，再增加复杂度；每天保留运行记录。
- 3. 周中检查：审查数据泄漏、随机种子、切分、指标和文件路径。
- 4. 周末交付：整理 Notebook、脚本、图表和文字结论，对照验收表自查。
- 5. 周末复盘：记录已完成、未完成、风险、下周依赖和一个最重要改进点。

## 8 周项目实施计划

| 周次    | 阶段目标       | 主要工作                                        | 验收标准                               |
|-------|------------|---------------------------------------------|------------------------------------|
| 第 1 周 | 冻结问题与数据起点  | 业务研究、数据合同、字段字典、数据质量检查、路线图和 risk 表           | 3 份第一周交付物完成 v1；至少 8 个因素；质量问题有数量和建议 |
| 第 2 周 | 看懂流失模式     | 完成单变量和多变量 EDA；建立客户画像；提出可验证假设；制作 Power BI 初版 | 至少 15 个有效图表、5 个假设；图表有问题、结论和限制      |
| 第 3 周 | 建立可复用清洗流程  | 将类型修复、缺失处理、编码和标准化放入脚本/Pipeline；写数据测试        | 一条命令生成处理数据；无硬编码路径；关键质量规则通过         |
| 第 4 周 | 构建可解释特征集   | 增加服务、费用、交互、聚合和代理时间特征；比较特征选择方法               | 至少 50 个有定义的候选特征；来源、公式和泄漏审查完整       |
| 第 5 周 | 建立可信基线     | 设计适合数据条件的切分；训练逻辑回归和决策树；比较类别权重与采样            | 基线报告含 AUC、PR-AUC、F1、召回率、校准和混淆矩阵    |
| 第 6 周 | 优化模型但控制过拟合 | 训练三个 Boosting 模型；用 Optuna 调参；比较细分市场表现       | 固定验证流程；保存最优 Pipeline；如实说明与目标线的差距   |
| 第 7 周 | 让模型可解释、可使用 | 做全局和单客 SHAP/LIME；校准概率；设计风险等级和评分卡            | 前 10 个驱动因素、典型客户解释、明确风险阈值和使用限制      |
| 第 8 周 | 连接风险与客户分群  | 构造代理 RFM；比较 K-Means 与 DBSCAN；建立风险-价值四象限     | 分群稳定性和业务含义可解释；输出优先客户群及边界           |