

特征工程设计文档 V1

本周实现基础清洗、字段合同以及可复用标准化/编码接口。W4 再实现并审查至少 50 项候选特征；W5 才完成正式基线评估。本文件设计 12 项真实时间序列特征，但当前 Telco 无真实事件日期，不能计算它们，更不能虚构日期凑数量。

现有接口与数据结构

层次	字段构成	本周状态与下游用途
原始输入	21 个 Telco 字段	原文件保持只读，读取时保留空白用于审计
清洗主表	原 21 列 + churn_label / total_charges_missing / tenure_zero / internet_applicable，共 25 列	TelcoCleaner 统一类型与类别，保留未知累计金额
特征输入 X	3 个数值 + 16 个类别 + 3 个非标签标记，共 22 列	split_xy 严格白名单，客户 ID 和两种标签均不进入
目标 y、追踪键	churn_label 、 customerID 单独返回	y 是 Yes→1 / No→0，ID 只负责核对同一客户
数值矩阵	3 个缩放数值 + 43 个独热列 + 3 个原样标记，共 49 列	仅为预处理示例；不是已经选择的 49 项独立业务发现，也不是 W4 最终特征集

具体字段、顺序和合法类别由 [w3_cleaning.json](#) 定义。清洗主表允许 [TotalCharges](#) 未知；预处理用训练内插补生成可供算法接收的有限数值。

输入字段处理方法

组别	字段	变换与风险
数值 3 项	tenure、MonthlyCharges、TotalCharges	训练中位数插补，然后训练均值/标准差缩放；金额只代表快照费用，不是正式 CLV
类别 16 项	gender、SeniorCitizen、Partner、Dependents、PhoneService、MultipleLines、InternetService、OnlineSecurity、OnlineBackup、DeviceProtection、TechSupport、StreamingTV、StreamingMovies、Contract、PaperlessBilling、PaymentMethod	逐列固定合法类别独热编码；SeniorCitizen 是 0/1 类别，不当连续年龄；未知类别报错
标记 3 项	total_charges_missing、tenure_zero、internet_applicable	保持 0/1 不缩放；分别表示信息缺口、静态边界、服务适用性

所有快照字段的实际采集日均未知，因此不能证明它们严格早于标签确认时刻。本项目只能称为静态快照分类练习；这种整体限制必须随模型报告保留，不能因为排除了 Churn 就声称已经证明没有时点泄漏。

拟合与转换的边界

清洗规则本身不学习全样本统计，可以先用于合同检查。插补中位数、均值、标准差等参数则必须先划分数据、只在训练子集 fit，之后留出部分只 transform。类别字典来自自己登记的业务合同，使用固定字典并不是观察留出标签。

实际接口是 `build_preprocessor()` 返回未拟合 sklearn Pipeline：`FeatureContract` → `ColumnTransformer` → `FiniteArrayGuard`。数值分支为 `SimpleImputer(strategy='median', keep_empty_features=True)` → `StandardScaler`；类别分支为固定 categories 的 `OneHotEncoder(handle_unknown='error')`；三个标记直通。

训练某个数值列若全部缺失，接口保留该列并使用计算用 0 回退，同时保留缺失标记。这里的 0 不是确认后的历史账单金额；清洗主表仍为未知，不能回写。缺失标记的预测价值以后也要在训练中验证，不默认它必然有效。

静态候选特征设计

下表是可实现候选，不表示本周已全部生成。每项落地前应登记版本和测试，并与基线比较。阈值或分位点若需要从样本学习，必须仅从训练折估计。

编号	候选名/类别	公式与来源	缺失、分母及泄漏注意	当前状态
S01	internet_addon_count / 行为	六项互联网增值服务中 Yes 的数量	只在 internet_applicable=1 人群中解释 0–6；无互联网保留不适用标记，不把它当真实使用频率	W4 候选，现有字段可算
S02	internet_addon_share / 行为	S01 / 6，限互联网客户	固定分母来自六项明确服务目录；它是订购覆盖率，不是实际使用深度	W4 候选，现有字段可算
S03	security_support_bundle / 行为	OnlineSecurity=Yes 且 TechSupport=Yes	同时保留无互联网不适用语义；关联不等于购买组合能减少流失	W4 候选，现有

编号	候选名/类别	公式与来源	缺失、分母及泄漏注意	当前状态
				字段可算
S04	phone_multiline_bundle / 行为	PhoneService=Yes 且 MultipleLines=Yes	无电话是结构性状态；检查前置逻辑一致性	W4 候选，现有字段可算
S05	automatic_payment / 合同支付	PaymentMethod 为 Bank transfer (automatic) 或 Credit card (automatic) 时为 1	自动付款不等于自动续约；不能替代 H8 真实续约记录	W4 候选，现有字段可算
S06	contract_tenure_interaction / 交互	各合同类型独热列 × tenure	合同枚举无自然连续大小关系；不把月付=0、一年=1、两年=2 默认当等距数值	W4 候选，现有字段可算
S07	monthly_charge_service_interaction / 交互	MonthlyCharges × S01，限适用客户	分析时保留服务适用性；不根据全体中位数先固定最终模型高费用组	W4 候选，现有字段可算
S08	historical_average_charge / 价值代理	TotalCharges / tenure，限 tenure>0 且金额已知	零年限或未知金额先保留 NA 和适用标记；不是终身价值，不从未知零值构造比率	W4 候选，现有字段可算
S09	charge_product_gap / 账单诊断候选	TotalCharges – tenure×MonthlyCharges，限金额已知	调价、折扣不可见；只作候选，不因差值大判错；须检查与原金额字段共线性	W4 候选；W3 仅做诊断
S10	log1p_total_charges / 价值变换	log(1+TotalCharges)，限非负实值	缺失仍缺失；后续插补拟合只使用训练；变换不解决 CLV 数据缺口	W4 候选，现有字段可算
S11	dependents_partner_profile / 人口统计	Partner × Dependents 的四种组合	需评估各组样本量、公平性和实际作用，不将群体身份解释为必然流失原因	W4 候选，现有字段可算
S12	tenure_basis / 静态年限变换	预先定义的 tenure 分段，或训练内拟合的样条/分位点	tenure 是静态月数；十种分箱仍不等于十个真实时间序列特征	W4 候选，现有字段可算

这些候选覆盖行为、费用价值代理、交互、人口统计和静态年限。最终候选数达到至少 50 时，须包含明确公式和来源，避免仅复制同一列凑数。时间类别在真实历史缺失时仍标注数据缺口。

真实时间特征的统一数据合同

定义 T 为每个客户一次评分的真实观察截止时刻。统一使用 UTC 存储，展示时可转换时区；按“天”聚合时需事先约定业务时区。所有历史窗口采用左闭右开 $[T-\text{窗口}, T)$ ，刚好发生在 T 的事件不进入输入。每条事件还需有 `available_at`（系统实际能取得该条记录的时刻），同时满足事件时间和 `available_at` $\leq T$ ，避免把事后补录数据用于过去评分。

公共必需字段为稳定 `customer_id`、快照 `as_of_time=T`，事件表还需唯一 `event_id`、`event_time` 和 `available_at`。先按事件键处理重复和更正版本，不按行号拼接；更正记录也只能使用截至 T 可见的版本。不同表必须有可验证的一致客户键与业务范围。

另需覆盖登记 `coverage_start`、`coverage_end`、采集状态，说明窗口是否完整。完整采集窗口内没有事件，计数可以为 0；采集停止或观测不足，不能把“没数据”当“没行为”。均值、比例和增长率遇到无分母或历史不足时记 NA，加覆盖/适用标记；插补留在训练内。

下表 12 项均是真实历史设计。当前 Telco 只有静态 `tenure` 和费用/订购状态，无这些事件表，因此每项的设计已交付，实际计算均待真实数据。不能用本机当前日期减 `tenure` 生成注册日，也不能把当期月费复制 30 次当作日用量。

12 项时间序列特征设计表

为避免宽表省略关键条件，分成两个平行表；编号连续，合计 12 项。以下每行均继承第 5 节公共键、 T 、`available_at` 和窗口覆盖要求。

编号/名称	公式及窗口	必需真实字段	缺失与边界	时点泄漏检查	可计算状态
T01 <code>api_calls_7d</code>	$[T-7\text{天}, T)$ 内合法 API 请求数量之和	请求日志 <code>event_id</code> 、 <code>event_time</code> 、 <code>request_count</code> 、 <code>available_at</code> ，客户键和 7 天覆盖记录	完整覆盖无请求→0；日志缺段→NA+coverage flag；负计数拒绝	只累计事件发生在 T 前且已入库的请求，去重复请求 ID	设计完成；Telco 缺日志，未计算

编号/名称	公式及窗口	必需真实字段	缺失与边界	时点泄漏检查	可计算状态
T02 api_calls_30d	$[T-30\text{天}, T)$ 内请求数量之和	与 T01 相同，需完整30天覆盖	新客户不足30天保留 actual_observed_days 和不完整标记；不与完整30天总量直接混为同口径	不补入 T 后迟到记录；不能用月末回填结果重写过去输入	设计完成；Telco 缺日志，未计算
T03 api_growth_30d	$(U_{\text{最近}30\text{天}} - U_{\text{前}30\text{天}}) / U_{\text{前}30\text{天}}$ ；比较 $[T-30\text{天}, T)$ 与 $[T-60\text{天}, T-30\text{天})$	60天请求日志、request_count、覆盖记录	前段为0→NA并加 zero_baseline；任何一段不完整→NA；不用随意加1改变增长定义	两段都严格位于 T 前；增长基准不使用评分后的完整月份	设计完成；Telco 缺历史，未计算
T04 active_days_30d	$[T-30\text{天}, T)$ 内 request_count>0 的不同业务日期数	event_time、request_count、业务时区、30天覆盖记录	完整无活跃→0；覆盖不足另记 observed_days；日期按冻结时区计算	不用评分之后发生的请求把 T 当天标成整日活跃；固定窗口边界	设计完成；Telco 缺日活动，未计算
T05 usage_cv_30d	$[T_d-30\text{个业务日}, T_d)$ 的30个完整日桶请求量总体标准差/均值；T_d 为不晚于T的最近业务日界线	日级请求序列、业务日期、计数、每日采集状态	完整无请求日补0；均值 0→NA+zero_usage；缺采集日不得补0	使用截止 T 前已完整结束且可见的30个日桶；不能包含当前未结束整日的最终值	设计完成；Telco 缺日序列，未计算
T06 usage_slope_30d	对 $[T_d-30\text{个业务日}, T_d)$ 的30个完整日桶拟合 $u_d = a + b \times d$ ，取最小二乘斜率 b	与 T05 相同，d 为按顺序的相对日号	完整常量序列斜率0；少于30个完整日桶→NA，另记历史长度	单客户局部历史公式不访问 y；只用 T 前结束且已取得的日桶	设计完成；Telco 缺日序列，未计算

T05/T06 特别采用最近 30 个已结束业务日，截止日界线为 T_d ；其他滚动特征按表中 T 截止。自然日按冻结的业务时区划分，遇到夏令时可能不是24小时。不能偷偷使用 T 之后的数据补齐尚未结束的当天，也不能把完整日窗口与最近720小时窗口混用。

编号/名称	公式及窗口	必需真实字段	缺失与边界	时点泄漏检查	可计算状态
T07 days_since_last_usage	$T - \max(\text{event_time})$ 换算天数，搜索 $[T-90\text{天}, T)$ 内已知合法活跃事件	活跃 event_time、available_at、90天覆盖、首次可观察日	90天完整但无事件→NA并加 no_usage_90d=1，表示至少90天未知上界；历史不完整另记 coverage，不能混成确切90天	不用最新全历史最大事件时间；只在 T 前窗口取 max	设计完成；Telco 缺活跃时间，未计算
T08 session_count_30d	$[T-30\text{天}, T)$ 内开始的去重 session_id 数	session_id、session_start、available_at、客户键、覆盖状态	完整采集无会话→0；缺 session_id 或来源中断→NA/异常登记；跨窗口会话按开始时刻归属	不要求会话必须在 T 后结束才计数，不能以未来结束状态筛选	设计完成；Telco 缺会话表，未计算
T09 request_error_rate_30d	$[T-30\text{天}, T)$ 中错误请求数/有效结果的请求数	请求ID、event_time、result_code、result_available_at、合法错误码字典	分母 0→NA+no_request；无结果请求单列，不直接算成功；计数分母与错误码定义同版本	结果也必须在 T 前可知，不能用 T 后最终重试成功状态覆盖过去错误	设计完成；Telco 缺请求结果，未计算

编号/名称	公式及窗口	必需真实字段	缺失与边界	时点泄漏检查	可计算状态
T10 <i>tickets_created_30d</i>	<i>[T-30天,T)</i> 内去重 ticket_id 数	可验证 customer_id、ticket_id、created_at、available_at、工单采集覆盖	完整覆盖无工单→0；当前已有工单数据无可靠 Telco 键，禁止按姓名/行号关联	只使用 T 前创建且可见工单；不依据未来结案或流失结果决定纳入	设计完成；Telco 缺可验证关联，未计算
T11 <i>resolved_ticket_hours_90d</i>	对创建于 <i>[T-90天,T)</i> 且截至 T 已知解决的工单，平均 <i>(resolved_at-created_at)</i> 小时	可靠客户键、ticket_id、created_at、resolved_at、resolution_available_at、截至T状态版本	无已解决工单→NA；未解决工单另报 unresolved_count，不能视为0小时；负时长拒绝；指标有只看已解决样本的选择偏差	resolved_at<T 且 resolution_available_at≤T；不得使用导出日已结案的最终状态回填过去	设计完成；缺可靠键和状态历史，未计算
T12 <i>days_to_contract_renewal</i>	<i>(next_renewal_at-T)</i> 天，使用截至 T 已生效且可见的合同版本；逾期可保留负值并加 overdue 标记	客户键、合同ID、valid_from/valid_to、recorded_at、next_renewal_at、自动续约规则	无续期日/不适用合同→NA+applicability；非唯一有效合同需先定义账户级聚合；不能仅凭 One year 猜真实日期	允许 T 时已知的未来计划日期，禁止使用 T 后变更后的实际续约结果或取消日	设计完成；Telco 缺合同日期，未计算

T11 是截至 T 可观察的“已解决工单平均处理时长”，不是全体工单最终平均时长。T12 使用未来的计划日期本身不必然泄漏，关键在于该计划在 T 时是否已知；事后真实续约结果不能进入。