

W3 数据清洗前后对比报告

1. 本次实际结果

原始 Telco 的 7,043 位客户全部保留，生成 25 列清洗主表。流失 1,869 人、未流失 5,174 人，客户顺序、编号与标签对应关系不变。主表保留 11 个未知累计费用，并添加明确缺失标记；模型矩阵经过训练内插补后，缺失和无穷值为 0。

这批数据通过 46 条已实现的质量检查，失败数 0。其中已知缺失和零年限边界属于“保留并说明”，不是偷偷删除后宣称所有问题不存在。数据源为公开教学代理，结论不等于 Azure 真实客户结论。

2. 清洗前后对账

metric	before	after	policy
rows	7043	7043	preserve
columns	21	25	add 4 documented fields
unique_customer_ids	7043	7043	preserve
churn_yes	1869	1869	preserve
churn_no	5174	5174	preserve
total_charges_blank	11	0	blank converted to NA
total_charges_explicit_na	0	11	preserve unknown meaning
total_charges_semantic_missing	11	11	preserve
total_charges_nonempty_parse_failure	0	0	strict conversion rejects invalid tokens
zero_tenure	11	11	preserve
no_internet	1526	1526	preserve
internet_customers	5517	5517	preserve
monthly_charges_iqr_outliers	0	0	diagnose, no winsorization
dropped_rows	0	0	no deletion

原 CSV 读取时所有列暂存为字符串，因此累计费用空白在读取层不是 pandas NA。清洗将其改成显式 NA；信息的未知数量没有增加，也没有被虚构补全。没有删除行、去重删人、缩尾或修改已知累计金额。

逐字段类型和缺失见 [字段审计](#)，逐类别人数见 [类别前后对账](#)。主表新增 churn_label、total_charges_missing、tenure_zero、internet_applicable；前者只用作目标，后三者可以进入特征。

3. 异常与账单关系

rule	count	action	basis
missing_TotalCharges	11	retain_and_flag	data contract
zero_tenure_boundary	11	retain_and_flag	Legal lower boundary, not deleted

完整检查及分母见 [质量检查表](#)。非法类别、重复/空客户键、数值非有限值、违规范围和服务逻辑冲突会报错。当前样本最大值不是永久业务上限；IQR 只是分布诊断。

下面计算 $TotalCharges - tenure \times MonthlyCharges$ ，单位与源费用字段一致：

statistic	value
count	7032
mean	0.153193
std	67.2553
min	-370.85
1%	-190.138
25%	-28.65
50%	0
75%	28.7
99%	191.46
max	373.25

4. 标准化、编码与防泄漏

X 有 22 列：3 个数值、16 个类别、3 个标记；不包含 customerID、Churn 或 churn_label。独热展开后共 49 列。固定种子 42，按标签分层切分，留出比例 0.2，本周只演示预处理接口。

split	rows	churned	churn_rate	missing_total_charges	matrix_columns	nonfinite_values
train	5634	1495	0.265353	8	49	0
validation	1409	374	0.265436	3	49	0

以下参数只从训练子集拟合：

field	training_median	training_mean_after_imputation	training_scale	training_variance	fit_rows	training_nonmissing	all_missing_fallt
tenure	29	32.4851	24.5666	603.516	5634	5634	False
MonthlyCharges	70.5	64.93	30.1354	908.144	5634	5634	False
TotalCharges	1398.12	2301.32	2277.61	5.18749e+06	5634	5626	False

training_median 是训练中位数，training_mean_after_imputation 和 training_scale 是插补后的训练均值和标准差；缩放为 (数值-训练均值)/训练标准差。all_missing_fallback_used 表示整列训练数据缺失时是否用了计算用 0，本次可直接查看该列。该回退与一般训练中位数插补均不反写清洗主表。

5. 交付位置与复现证据

- 清洗主表和客户级追踪：data/processed/w3/，共 9 份 CSV；X、y、ids 的同名拆分文件严格按行对应，勿单独排序。
- 已拟合预处理器与 49 列名称：models/w3/，这不是预测模型。
- 清洗规则 C01-C10、特征工程设计 v1、运行说明。
- 本次配置、代码和业务产物指纹、新进程与 Notebook 验证、隔离环境验证。这些验证文件分别记录自身执行状态；未运行的检查不能由本报告代替。
- 已执行 Notebook 与 浏览器阅读版 展示清洗和训练内变换过程。