客户流失预测与价值分层研究

基于公开代理数据的实证分析

摘要

针对客户流失识别与资源配置问题，本文基于公开客户数据，研究特征构建、预测建模、模型解释、推理优化和价值分层。监督学习使用 7,043 名 Telco 客户，其他资料因缺少可靠关联键未合并训练。比较传统分类器、树集成、表格模型及概率融合后，保留历史 XGBoost 模型；其验证集 AUC 为 0.852193，F1 为 0.656160，召回率为 0.817857，未达到预设效果目标。保持预测输出不变的工程优化将 1,056 行热请求中位耗时由 52.26 ms 降至 10.14 ms，主要收益来自数据校验、特征派生和编码。风险与月费矩阵识别出 294 名高月费高风险客户，占验证集 27.84%，对应月费占比 37.31%。研究形成了可复核的分析流程，但公开代理数据、验证集重复使用及时间信息不足限制了外部推广；月费分层不能替代真实生命周期价值或因果收益估计。

关键词：客户流失；特征工程；模型解释；推理优化；客户分群

1 引言

客户流失研究需兼顾预测质量、运行成本与客户价值，并区分横截面关联、动态行为及干预效果。

本文以 Azure 客户管理为背景，使用公开代理数据验证方法，研究对象并非真实 Azure 客户。研究覆盖数据治理、特征与模型比较、解释、推理优化及风险与月费分层。贡献在于可审计的实证比较和工程实现，不涉及新算法；按预测效果、运行效率和描述性业务结果分别评价。

2 数据与研究设计

2.1 数据来源与清洗

采用已归档的三类公开数据[1,2,3]。Telco 包含 7,043 名客户和 21 个原始字段，流失客户 1,869 名，占 26.54%；工单资料包含 8,469 条记录、17 列；SaaS 资料由十张汇总表构成，共 50 条记录。三者缺少可信共同客户键及预测前时间关系，故仅 Telco 用于监督学习，其他资料用于独立分析。

清洗保留全部客户及原标签。累计费用字段的 7,032 个非空值全部成功转换为数值，11 个空白保留为缺失，不视为真实零金额。清洗表包含 25 列；排除标识与目标后，19 项业务属性及 3 项确定性标记构成 22 项输入。模型所需插补、标准化和编码参数仅在对应训练范围内估计。

探索分析显示，月付、一年及两年合同客户的流失比例分别为 42.71%、11.27%和 2.83%，合同关联的 Cramér's V 为 0.4101。分析服务组合时必须固定适用人群：互联网客

户中，附加服务数量与流失标签的 Spearman 相关为-0.2879；加入无互联网客户后相关减弱至-0.0600，说明结构性“不适用”会改变统计关系。上述结果仅支持横截面关联。

2.2 样本划分与评价协议

正式建模采用随机种子 42 的分层划分，训练、验证及历史测试集分别为 4,930、1,056 和 1,057 人，正类分别为 1,308、280 和 281 人。训练集内实施五折交叉验证。缺少可信事件日期使时间切分不可实施；早期全量探索及历史测试记录也意味着现有测试集不能视为完全未接触的盲测。

评价指标包括 AUC、平均精确率 AP、正类 F1、Precision、Recall 及 Brier 分数。AP 不等同于梯形积分的 PR 曲线面积。早期候选在验证集选择阈值，后续候选主要依据训练集折外预测（OOF）确定阈值；两类协议分别标注，不进行无条件比较。最终模型区间采用固定模型与阈值下的分层 bootstrap，不包含重新训练和模型选择的不确定性。

3 研究方法

3.1 特征构建与模型比较

特征工程由 22 项基础输入构建 64 项逻辑候选，编码后为 111 列。互信息、L1 正则和递归消除用于筛选，并结合方差、相关性与方差膨胀因子诊断。交叉验证期间，估计与筛选仅在训练折拟合。该实验使用 5,634/1,409 的开发与留出划分，与正式建模划分不同，故仅在自身协议内比较。全开发集筛选器最终保留 27 列，未满足至少 50 项最终特征的要求；预设筛选上限 40 亦低于该目标。

基线比较两种特征表示、Logistic 回归与决策树，以及原比例、类别权重、SMOTE 和 ADASYN，共 16 个候选。重采样限定于训练集。进一步比较 XGBoost、LightGBM、CatBoost、SVC、ExtraTrees、样条 Logistic、EBM、TabPFN、TabM 和 TabICLv2，并研究 Stacking、Blending、分组专家、focal 损失与排序目标。树模型及自动搜索分别采用已有算法和 Optuna 框架[4,5]。

实验登记共 19 条研究路线、46 条验证记录及 155 条 OOF 评分记录，包含重复基线、阈值探索、学习曲线和算术融合，不代表相同数量的独立模型。后期采用 min(F1/0.80,AUC/0.88)衡量联合目标完成程度。

3.2 解释与风险容量

对冻结模型采用 Tree SHAP，以 tree_path_dependent 模式在对数优势空间分解预测，将编码列的带符号贡献聚合至逻辑变量，再计算平均绝对贡献[6]。局部解释比较 LIME 代理模型，要求各随机种子的加权留出 $R^2 \geq 0.70$ 且个体概率误差≤0.05[7]。

风险分值定义为 100p，按未舍入概率划分低风险[0,0.10)、中风险[0.10,0.30)和高风险[0.30,1]。阈值 t 对应人数为预测概率不低于 t 的客户数。容量分析保留全部同分客户，预

算阈值仅依据概率确定，标签用于事后评价；零候选时精确率不定义。分析复用冻结概率，不重新优化原阈值。

3.3 运行优化与价值分群

推理优化保留 240 棵树、111 列输入与原阈值，通过 NumPy 派生特征、冻结统计量复用、直接编码和 4,096 行分块降低开销。保留 float64 运算顺序后转为 float32，以降低数值差异风险。延迟以独立进程交替请求测量；阶段分析采用互斥计时，以原、新总耗时之比计算加速比，各阶段节省占总节省的比例表示贡献。

价值侧以训练月费中位数为界，展示为 70.575，按未舍入值及≥规则分层；风险侧固定 p≥0.30，非高风险包括低、中风险。月费仅为价值代理。聚类使用 13 维静态订阅表示，排除标识、标签、预测概率、风险档及累计费用。任期与月费经 log1p 转换后，与附加服务数按训练统计标准化；二值标记及分组缩放的独热变量共同构成距离表示。

KMeans 比较 k=2 至 6，以训练轮廓系数选择全覆盖方案；DBSCAN 比较两种最小样本数与三种邻距分位数组合。验证客户仅在训练核心点的 eps 半径内通过最近邻规则分配，否则保留未分配状态。该规则属于外部扩展，并非 DBSCAN 原生预测接口[8]。

4 结果

4.1 特征增益与预测性能

在固定 Logistic 分类器的五折对照中，基础 49 列、工程 111 列及折内筛选 27 至 29 列的 AP 均值分别为 0.6615、0.6677 和 0.6699。后验十次五折复核中，筛选相对基础的 AP 平均差为 0.008954，近似 95%区间为[-0.001377,0.019284]，Bonferroni 校正 p=0.2635。采用考虑训练重叠的近似配对检验后，仍不足以认定显著提升；重复划分不等于独立新样本。

表 1 冻结验证集上的代表模型

模型	阈值及选择数据	AUC	F1
Logistic 基线	0.35，验证集	0.848764	0.637195
保留 XGBoost	0.30，验证集	0.852193	0.656160
受控 XGBoost 候选	0.54，训练 OOF	0.847945	0.649573
ExtraTrees	0.26，训练 OOF	0.849749	0.648062
CatBoost 与 EBM 融合	0.50，训练 OOF	0.849169	0.632061
三组件融合	0.47，训练 OOF	0.850647	0.630468

表 1 中的保留模型源于历史候选回顾，未重新训练。其验证集 TN、FP、FN、TP 分别为 587、189、51 和 229；Precision 为 0.547847，Recall 为 0.817857，AP 为 0.653586，Brier 为 0.133260。1,000 次按类别分层 bootstrap 得到 AUC 的 95%区间[0.827687,0.874718]、F1 区间[0.623591,0.687410]。这些条件区间未经多轮选择偏差调整。

三组件融合相对保留模型减少 15 个误报，却增加 20 个漏报，F1 下降 0.025693，未支持替换。历史测试集 AUC=0.847429、F1=0.622735 仅属于 Logistic 基线，不属于最终 XGBoost。

细分评估覆盖合同、网络服务及任期的十个层次，八层满足样本数≥100 且正负类各≥20。各合格层进行 500 次配对 bootstrap，要求相对整体 AUC、F1 差值区间下限分别高于-0.10、-0.15。仅光纤客户和任期 13 至 24 月组满足规则，另两层样本不足无法判断。因此 AUC≥0.88、F1≥0.80 和至少三个稳定细分的目标均未达成。

4.2 解释结果与容量权衡

训练集前十因素占平均绝对归因的 71.35%，该比例并非解释方差。固定验证集 SHAP 行的 500 次 bootstrap 中，前十入选频率均为 100%，但不代表重训或时间稳定。六例 LIME 分析仅一例同时满足拟合度与个体误差要求，故正式解释以树 SHAP 为主。

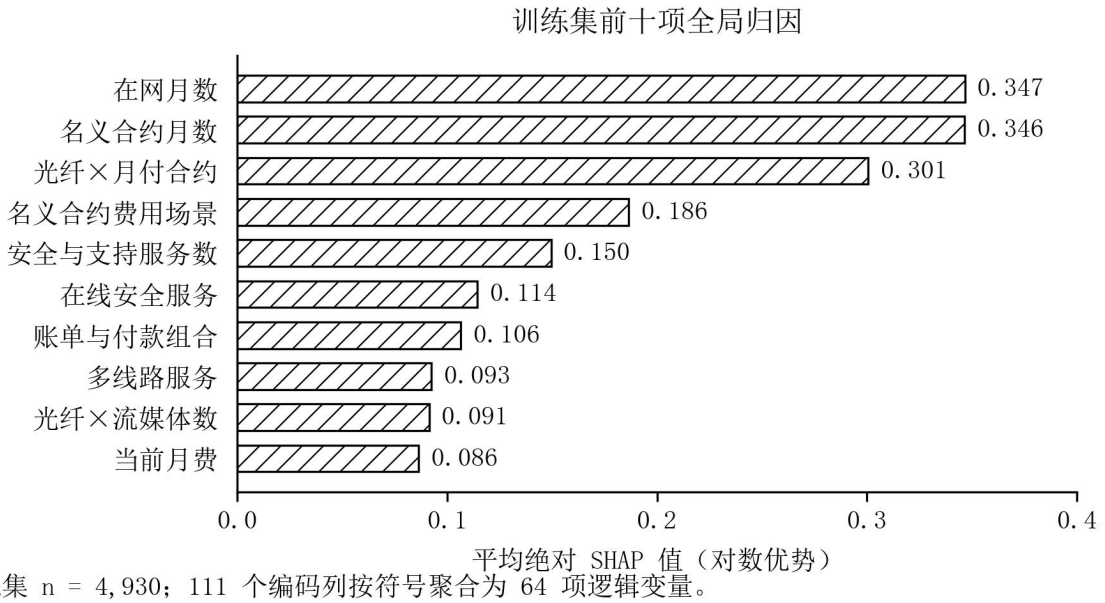


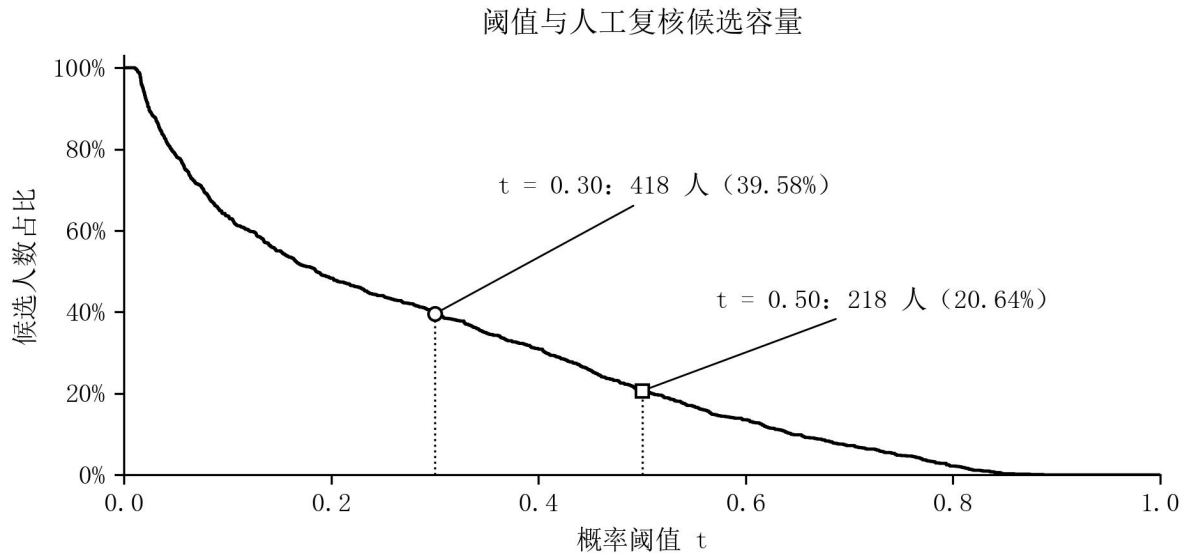
图 1 训练集确定的前十逻辑变量。平均绝对 SHAP 的单位为对数优势，归因不具有因果含义。

验证集低、中、高风险人数分别为 385、253 和 418，历史流失率分别为 2.60%、16.21%和 54.78%。十个等宽箱的 ECE 为 0.031745；此为概率质量诊断，未重新拟合最终模型的校准器。

表 2 阈值与候选容量

阈值	候选人数	历史流失人数	Precision	Recall
0.10	671	270	40.24%	96.43%
0.30	418	229	54.78%	81.79%
0.50	218	146	66.97%	52.14%

阈值由 0.30 升至 0.50，候选减少 47.85%，精确率增加 12.19 个百分点，召回率下降 29.64 个百分点。40%人数预算允许 422 人，但同分约束下最多选择 418 人；下一组 6 人全部加入将超额。候选容量不等于工时、干预成功人数或收益。



历史验证集 n = 1,056；候选口径为 p ≥ t，同分组不拆分。
0.30 为冻结政策；0.50 仅作容量情景，未重新选择阈值。

图 2 历史验证集的阈值容量曲线。人数按整组同分客户变化，固定高风险阈值为 0.30。

4.3 运行效率

训练与验证合计 5,986 名客户的两列概率逐位一致，阈值决策无差异。2026-10-16 测量中，1、32、1,056 及 24,650 行热请求的 P50 加速分别为 6.50、6.36、5.15 和 2.58 倍；其中 1,056 行由 52.26 ms 降至 10.14 ms。最大负载由训练客户重复五次构成，不代表新增样本。

表 3 1,056 行请求的独占阶段平均耗时

阶段	原耗时/ms	新耗时/ms	加速比	节省贡献
输入校验	11.4432	4.1424	2.76	19.63%
特征构造	23.6031	1.5575	15.15	59.28%
编码	9.0593	1.4874	6.09	20.36%
树预测	2.2314	2.2564	0.99	-0.07%
输出包装	0.1566	0.0159	9.88	0.38%
其他开销	0.2232	0.0662	3.37	0.42%
合计	46.7168	9.5257	4.90	100.00%

表 3 来自 2026-10-21 的独立阶段测量，分项按显示精度四舍五入。校验、构造与编码贡献 99.27%的节省，树计算未加速。该测量的阶段均值可相加，加速比不可相加或相

乘；其 4.90 倍与不同日期的 P50 加速 5.15 倍不能混为同一分解。阶段归属亦不等同于逐项因果消融。

在 24,650 行负载下，进程生命周期 RSS 峰值由 302.46 降至 240.63 MiB，减少 20.45%；私有提交峰值减少 12.82%。工件由 244,675 缩至 27,785 字节，减少 88.64%，包含压缩收益；相对原工件 gzip 版本仅进一步缩小 17.32%。冷启动首结果加速约 1.076 倍，单独加载反而慢约 7.51%，且各仅三次观察，不能概括为所有阶段均显著改善。

4.4 分群与月费结构

KMeans 选择三个簇，训练与验证轮廓系数分别为 0.30258 和 0.29739。五个种子间最小 ARI 为 0.99816，仅表明初始化稳定。DBSCAN 选择 min_samples=25、eps=1.14359，训练得到两簇及 15 个噪声点；验证有 2 人未分配，覆盖 99.81%，非噪声条件轮廓系数为 0.31624。二者评价人群不同，轮廓系数不可直接比较。

训练轮廓系数采用固定 2,000 人子样本，DBSCAN 剔除噪声后为 1,996 人；验证分别采用全体 1,056 人和 1,054 名非噪声客户。

三个 KMeans 验证群体分别有 358、459 和 239 人，平均任期为 10.17、48.46 和 31.53 月，平均月费为 68.37、85.81 和 21.80。其画像分别表现为短任期月付合同集中、较长任期且附加服务较多、低月费结构。订阅开通状态不等于使用频率或活跃程度。

风险—月费代理四象限（历史验证集）

	非高风险（p < 0.30）	高风险（p ≥ 0.30）
高月费 ≥ 70.575	人数：237（22.44%） 月费总额：22,271.05 月费占比：32.24%	人数：294（27.84%） 月费总额：25,773.65 月费占比：37.31%
低月费 < 70.575	人数：401（37.97%） 月费总额：14,987.00 月费占比：21.70%	人数：124（11.74%） 月费总额：6,041.40 月费占比：8.75%

月费界限为训练中位数，显示为 70.575；占比均以全体验证集为分母。
历史验证集 n = 1,056；月费合计 69,073.10（数据集货币单位/月）。
当前月费为价值代理，不等同于利润或 CLV。

图 3 验证集风险与月费结构。月费以数据集货币单位/月计；高月费界限取训练中位数，非高风险包含低、中风险。

高月费高风险组 294 人，占 27.84%，月费总额 25,773.65，占 37.31%；其中 169 名历史流失客户占全部正类的 60.36%。三个比例分母不同，不能相互替代。训练月费第 40/60 百分位作界限时，验证集该组为 328/217 人，显示分层依赖阈值。按月费降序且不拆同费组，443 人覆盖 60.09%的月费；该集中度不代表利润贡献。风险乘月费仅用于情景排序，未估计未来存续期、毛利或干预效应。

4.5 分析与工程产出

数据治理保留来源指纹、字段定义和可复现清洗流程。探索阶段开展 7 项假设分析，形成 20 幅静态图、4 页 Power BI 原生报告及 15 图离线视图。历史 Desktop 刷新与 DAX 查询核对了客户及流失总数；报表导入本地嵌入快照，不代表 Azure 云端 ETL 部署。Telco 缺少客户级地区、行业及 Azure 订阅维度；12 项时间特征仅完成设计，实际未计算。特征与推理代码、序列化工件和自动化验收记录支持复核。

5 讨论

复杂算法与融合未显示稳定验证增益。样本规模、静态信息及噪声的独立影响尚不可分离，不能宣称达到数据理论上限。共享验证集的多轮选择偏差不能由固定模型 bootstrap 区间消除。

研究应区分预测细分稳定、固定模型归因重采样稳定、聚类初始化稳定和时间稳定。归因重采样稳定与聚类初始化稳定不能补足预测目标或时间外证据。合同与服务属性的统计关联和模型归因均不能直接解释为干预因果效应。

工程结果表明，预处理是小批量推理的重要开销来源；批量增大后，分块重复调用削弱总体收益。工件大小、数组空间与进程内存属于不同计量口径，概率一致性也仅在已检验输入与边界内成立。工程验收支持可复现性，不替代外部业务有效性。

价值分析受数据粒度限制。缺少最近交易日期、交易次数、成本及未来留存信息，无法构建真实 RFM 或 CLV。月费矩阵可支持人工核查顺序，但不能证明利润提升、留存改善或投资回报。

6 结论

本文形成了数据治理、特征与模型比较、解释、容量分析、推理优化及客户分群的完整流程。保留模型在验证集达到 AUC 0.852193 和 F1 0.656160，但效果与细分稳定目标未达成。运行优化在输出一致条件下降低了热请求延迟、内存与工件体积。风险与月费分层提供了可复核的客户优先级描述，其价值在于决策支持而非真实 CLV 或因果收益估计。

参考文献

[1] BLASTCHAR. Telco Customer Churn[DS/OL]. Kaggle, version 1[2026-10-23]. https://www.kaggle.com/datasets/blastchar/telco-customer-churn.

[2] SURAJ520. Customer Support Ticket Dataset[DS/OL]. Kaggle, version 1[2026-10-23]. https://www.kaggle.com/datasets/suraj520/customer-support-ticket-dataset.

[3] WEARETENET. SaaS Churn Rate Statistics Dataset[DS/OL]. Kaggle, version 1[2026-10-23]. https://www.kaggle.com/datasets/wearetenet/saas-churn-rate-statistics-dataset.

[4] CHEN T, GUESTRIN C. XGBoost: A Scalable Tree Boosting System[C]. KDD, 2016. DOI:10.1145/2939672.2939785.

[5] AKIBA T, SANO S, YANASE T, et al. Optuna: A Next-generation Hyperparameter Optimization Framework[C]. KDD, 2019. arXiv:1907.10902.

[6] LUNDBERG S M, ERION G, CHEN H, et al. Explainable AI for Trees: From Local Explanations to Global Understanding[EB/OL]. 2019. arXiv:1905.04610.

[7] RIBEIRO M T, SINGH S, GUESTRIN C. “Why Should I Trust You?”: Explaining the Predictions of Any Classifier[C]. KDD, 2016. arXiv:1602.04938.

[8] Scikit-learn developers. Clustering, version 1.5[EB/OL]. [2026-10-23]. https://scikit-learn.org/1.5/modules/clustering.html.