

Azure 客户流失预测与 CLV 提升：项目理解与个人 12 周计划

编写日期：2026 年 8 月 31 日

文档定位：这是基于项目 brief 的个人理解与执行计划，不是已经完成的数据分析报告。文中的模型指标和 ROI 数字属于验收目标，最终结果必须以实际数据和独立测试为准。

一、我对项目总体的理解

1. 项目的本质

这个项目不是单纯训练一个“客户是否流失”的分类模型，而是要建立一条从业务问题到留存行动的完整分析链路：

理解业务和定义口径

-> 检查数据是否可信

-> 预测谁可能流失

-> 解释为什么可能流失

-> 判断客户未来价值

-> 决定先干预谁、采取什么行动

-> 用实验或因果方法验证行动是否有效

-> 计算收益、成本和 ROI

最终目标不是得到一个漂亮分数，而是让客户成功团队能够回答四个实际问题：

1. 谁可能流失？

给每位客户一个经过校准的风险概率。
2. 为什么可能流失？

找到整体和单个客户的主要风险因素。
3. 谁最值得优先处理？

将流失风险与 CLV、毛利和干预成本结合。
4. 怎样证明挽留有效？

通过 A/B 测试、uplift 或因果推断估计增量效果。

2. 从业务问题到分析产出

业务问题	分析方法	主要产出
哪些客户可能离开	分类模型、概率校准、阈值分析	客户级流失概率和风险等级
哪些因素推高风险	EDA、SHAP、LIME、分群比较	全局驱动因素和单客原因
哪些客户最重要	RFM、行为分群、CLV	风险-价值矩阵和优先名单
应采取什么行动	驱动因素到策略映射、成本收益分析	分层留存策略和行动手册
行动是否值得	A/B 测试、因果推断、敏感性分析	增量留存、增量 CLV 和 ROI

3. 数据在本项目中的位置

PDF 推荐的 Telco Customer Churn 数据适合练习端到端流程，但它是电信代理数据，不是微软内部 Azure 客户数据。我的实现将分成两层：

- MVP 层：

先用 Telco 数据完成数据质量检查、EDA、基线模型、解释和简化风险-价值分析。

- **进阶层**：只有在获得合法且时间口径一致的数据后，才加入云资源使用趋势、工单、交易序列、时间切分、正式 CLV 和因果评估。

在任何分析开始前，都必须固定以下定义：

- 一行数据代表客户、企业账号、订阅还是资源组。
- 哪一天是观察截止日，预测未来多少天。
- 什么情况算流失，是否有宽限期和标签延迟。
- 收入、毛利、贡献利润和 CLV 使用哪一种价值口径。
- 哪些字段在预测时已经可知，哪些属于未来信息或泄漏。

4. 我对“项目成功”的判断

我会从四个层面判断项目是否成功：

1. **数据可信**：数据来源、字段含义、质量问题和处理规则都有记录。
2. **模型可信**：切分方式合理，无数据泄漏；同时报告 AUC、PR-AUC、F1、召回率、精确率、校准和分群表现。
3. **业务可用**：风险分数能够对应客户、原因、价值、行动和负责人，而不是停留在 Notebook。
4. **效果可证**：明确区分相关性、预测效果和干预的因果效果，并报告成本、不确定性和限制。

brief 给出的基线 AUC-ROC 0.75、优化模型 AUC-ROC 0.88、F1 0.80 和策略 ROI 300% 都是目标线。若真实数据无法达到，应如实解释原因，不通过泄漏、反复查看测试集或修改标签来凑指标。

5. 主要风险与应对原则

风险	可能后果	我的处理原则
代理数据被误写成 Azure 真实数据	结论失真，报告可信度下降	在标题、数据字典和结论中持续标注代理数据
标签和预测窗口不清楚	模型问题本身被定义错	第 1 周冻结数据合同，变更必须留版本记录
时间或目标泄漏	离线分数虚高	以观察截止日审查每个特征，预处理仅在训练集拟合
类别不平衡	只预测多数类也显得准确	使用 PR-AUC、召回率、阈值和成本共同评估
强行拼接不同公开数据	产生虚假的客户关系	无稳定键和时间口径就分开分析
把相关性当成干预效果	高风险策略可能无效或有害	用随机实验或明确因果假设估计增量效果
云资源产生费用	超出个人预算	本地完成 MVP；上云前设置预算、标签和清理规则

二、我对第一周任务的理解

1. 第一周真正要解决的问题

第一周不是急着训练模型，而是回答三个基础问题：

- 1. **业务问题是否定义清楚？** 明确客户、流失、预测时间和价值的含义。
- 2. **数据是否足以回答问题？** 看懂每列、确认来源，并系统发现质量问题。
- 3. **后续 11 周是否可执行？** 把任务、依赖、验收标准和风险写成路线图。

如果这一步含糊，后面的模型越复杂，返工和错误结论越多。因此第一周的核心产出是“统一口径和建立可信起点”。

2. Brief 要求的三类交付物

交付物	我对内容的理解	完成标准
《Azure 云服务业务与客户流失分析报告》	说明商业模式、客户旅程、流失机制、关键指标和待验证因素	至少提出 8 个有业务依据、可以被数据验证的因素
《数据质量评估报告》	记录数据来源、粒度、字段、缺失、重复、类型、范围、异常和逻辑冲突	问题有数量、比例、样例、严重度和处理建议，不只写“已检查”
整体路线图	将 12 周目标拆成里程碑、依赖、风险和完成定义	每周有输入、动作、输出、检查点和风险应对

3. 第一周的四个工作包

工作包 A：业务与客户流失研究

我会先理解 Azure 场景中的客户旅程：试用或购买、上手、资源采用、使用扩张、续约、降配或取消。研究内容包括订阅与按量付费、合同周期、支持服务、客户成功和云成本管理。

第一周至少形成以下 10 个**待验证假设**，它们不是结论：

- 1. 月付或短合同客户的流失风险可能高于长期合同客户。
- 2. 新客户在上手早期使用不足时更容易流失。
- 3. 近 30/90 天使用量持续下降可能早于正式取消。
- 4. 使用的服务种类少、关键功能采用浅可能代表粘性不足。
- 5. 费用快速上升但使用价值没有同步增长可能增加流失风险。
- 6. 支付失败、欠费或账单争议可能是短期风险信号。
- 7. 工单频繁、严重或解决时间长可能降低续约意愿。
- 8. 自动续费设置、历史续约次数可能影响流失概率。
- 9. 行业、地区和企业规模可能改变客户对价格和支持的敏感度。

10. 高风险因素在高价值与低价值客户中可能有不同的干预优先级。

工作包 B：数据理解与数据合同

我会为 Telco 代理数据建立字段字典，至少记录：字段名、中文含义、数据类型、单位、允许值、缺失规则、业务可用时间和是否可能泄漏。

同时写出数据合同初稿：

- 主体粒度：一行代表一个客户。
- 唯一键：确认 `customerID` 是否唯一且非空。
- 标签：确认 `Churn` 的原始取值和转换规则。
- 时间限制：Telco 数据缺少完整快照时间，因此 MVP 不能假装完成严格时间切分。
- 价值字段：明确 `MonthlyCharges`、`TotalCharges` 的含义和局限。
- 数据来源：记录下载地址、下载日期、许可和文件哈希。

工作包 C：数据质量评估计划

数据质量检查不只是调用 `info()`，而是为每类问题留下可复核证据：

检查维度	具体检查	输出
文件与结构	文件能否读取、编码、行列数、列名	数据概况表
唯一性	客户 ID 为空或重复	重复记录清单
完整性	各列缺失数量、比例和缺失组合	缺失率表和热图
类型	数字被读成字符串、日期格式不一致	类型问题清单
合法范围	负费用、非法月份、异常类别	越界记录清单
一致性	总费用与服务年限矛盾、服务组合冲突	逻辑规则及命中数量
异常值	费用、服务数量等极端值	分布、箱线图和待确认样本
标签质量	标签比例、未知值、潜在重复标签	标签审计表
泄漏风险	预测时不可知或由标签直接产生的字段	泄漏审查清单

每个问题都要记录严重度、影响范围、可能原因、建议动作和是否需要业务确认。第一周只提出处理建议，不应在没有依据时直接删除异常客户。

工作包 D：路线图与风险登记

我会把 brief 的 12 周计划转成自己的可执行任务，并建立风险登记表。优先记录：数据获取失败、字段不匹配、时间字段不足、模型指标不达标、算力和 Azure 费用、隐私与发布风险。

4. 第一周每日安排

以下按每天约 2-3 小时、全周约 16 小时安排：

天	重点	具体行动	当天留下的证据
第 1 天	确认范围	重读 brief；写项目一句话目标、代理数据声明和术语表	范围说明、术语表、问题清单
第 2 天	研究业务	梳理 Azure 客户旅程、商业模式、续约与流失机制	业务笔记、来源清单、10 个待验证假设
第 3 天	获取数据	下载 Telco 数据；登记来源、许可、日期、大小和 SHA-256	原始文件登记表、哈希、目录结构
第 4 天	理解字段	确认行粒度、ID、标签、类型、单位和可用时间	数据字典初稿、数据合同初稿
第 5 天	质量检查	编写可重复的数据概况与质量检查 Notebook/脚本	缺失、重复、类型、范围和类别统计
第 6 天	形成报告	对问题分级；补充样例、影响和处理建议	数据质量报告、业务报告初稿
第 7 天	评审与规划	对照 brief 验收；完成 12 周路线图和风险表	三份交付物 v1、下周输入清单

5. 第一周完成定义 (Definition of Done)

第一周结束时，我要能够拿出证据回答：

- 数据来自哪里，能否合法用于学习和展示？
- 一行代表谁，客户 ID 是否唯一，标签是什么意思？
- 所有列的数据类型、含义、单位、取值范围和预测可用时间是什么？
- 缺失、重复、异常、非法类别和逻辑冲突各有多少？
- 至少 8 个业务因素如何映射到可检查字段或数据缺口？
- 哪些问题会阻挡建模，哪些可以在后续清洗时处理？
- 未来 11 周每周要交付什么，主要依赖和风险是什么？

第一周的非目标是：不追求最终模型分数，不强行合并三个公开数据集，不虚构 Azure 内部字段，也不把初步相关性写成因果结论。

三、我的个人 12 周计划

1. 时间和工作方式假设

我暂按每周 15-18 小时规划：学习与查资料约 20%，编码与实验约 45%，分析与文档约 25%，复盘与项目管理约 10%。如果某周时间减少，优先保证可复现的主流程和真实记录，删减高级加分项，不牺牲数据质量和独立测试。

周次	核心目标	我的主要行动	完成标志
第 1 周	冻结问题与数据起点	业务研究、数据合同、字段字典、数据质量检查、路线图和风险表	3 份第一周交付物完成 v1；至少 8 个因素；质量问题有数量和建议
第 2 周	看懂流失模式	完成单变量和多变量 EDA；建立客户画像；提出可验证假设；制作 Power BI 初版	至少 15 个有效图表、5 个假设；图表有问题、结论和限制
第 3 周	建立可复用清洗流程	将类型修复、缺失处理、编码和标准化放入脚本/Pipeline；写数据测试	一条命令生成处理数据；无硬编码路径；关键质量规则通过
第 4 周	构建可解释特征集	增加服务、费用、交互、聚合和代理时间特征；比较特征选择方法	至少 50 个有定义的候选特征；来源、公式和泄漏审查完整
第 5 周	建立可信基线	设计适合数据条件的切分；训练逻辑回归和决策树；比较类别权重与采样	基线报告含 AUC、PR-AUC、F1、召回率、校准和混淆矩阵
第 6 周	优化模型但控制过拟合	训练三个 Boosting 模型；用 Optuna 调参；比较细分市场表现	固定验证流程；保存最优 Pipeline；如实说明与目标线的差距
第 7 周	让模型可解释、可使用	做全局和单客 SHAP/LIME；校准概率；设计风险等级和评分卡	前 10 个驱动因素、典型客户解释、明确风险阈值和使用限制
第 8 周	连接风险与客户分群	构造代理 RFM；比较 K-Means 与 DBSCAN；建立风险-价值四象限	分群稳定性和业务含义可解释；输出优先客户群及边界
第 9 周	估算 CLV 与留存价值	先检查交易/频次假设；条件满足时用 BG/NBD 和 Gamma-Gamma，否则使用透明的订阅简化式	客户级 CLV、群体对比、假设清单和留存提升情景表
第 10 周	设计可验证的留存行动	将驱动因素映射到至少 5 种策略；估算成本；设计 A/B 测试与样本量	策略手册、成本表、实验单位、主指标、护栏指标和停止规则齐全

周次	核心目标	我的主要行动	完成标志
第 11 周	比较策略组合与不确定性	模拟至少 10 个组合；对效果、成本和折现做敏感性分析；估算 ROI 区间	不只报告单点 ROI；给出推荐组合、适用客户和失败条件
第 12 周	形成可复现交付	清理仓库；补 README、数据卡、模型卡；完成报告、PPT、Power BI 和演示	新环境可按说明复现；结果、限制和伦理边界一致；完成最终检查表

2. 每周固定节奏

为了防止只写代码、不形成成果，我每周采用相同节奏：

1. **周初定义**：写清本周问题、输入、输出和不做什么。
2. **周中实现**：先完成最小可运行版本，再增加复杂度；每天保留运行记录。
3. **周中检查**：审查数据泄漏、随机种子、切分、指标和文件路径。
4. **周末交付**：整理 Notebook、脚本、图表和文字结论，对照验收表自查。
5. **周末复盘**：记录已完成、未完成、风险、下周依赖和一个最重要改进点。

3. 每周都要保留的证据

- 可重复运行的命令和环境版本。
- 输入数据来源、处理步骤和输出路径。
- 指标表、图表、随机种子和实验配置。
- 失败实验及原因，而不只保留最好结果。
- 业务结论对应的图表或统计证据。
- 已知限制、仍需确认的问题和下一周输入。

四、暂停结束后的第一步

恢复项目时，我将先执行以下动作，而不是继续安装新工具：

1. 创建标准项目目录。
2. 下载 Telco Customer Churn 数据并登记来源与文件哈希。
3. 建立第一版数据字典和数据合同。
4. 编写只读的数据质量检查 Notebook 或脚本。
5. 按第一周完成定义整理三份交付物。

环境只有在验证失败或新任务确实需要新组件时才调整。所有后续工作都以“数据可信、过程可复现、结论不过度”为基本原则。